TP 2 — TEXT MINING MULTI-DATASETS & MULTILINGUE

Titre

Conception d'un système avancé d'analyse textuelle multi-tâches sur données mono-langue et multilingues

---

Contexte

Les entreprises exploitent aujourd'hui des données textuelles issues de multiples sources et langues.
Cependant, les performances des modèles varient fortement selon :

- la qualité des données
- la langue
- la représentation utilisée

Ce TP vise à étudier ces impacts dans un cadre expérimental rigoureux.

DATASETS UTILISÉS

Dataset 1 — Reviews (Mono-langue)

Caractéristiques :

- Langue principale : Anglais
- Avis clients produits
- Colonnes :
  - `text`
  - `rating`
  - `sentiment`
  - `product_category`

👉 Objectif :

- Cas standard (baseline)

Dataset 2 — Reviews Multilingues

Caractéristiques :

- Langues : EN / FR / Darija
- Avis similaires mais multi-langues
- Colonnes :
  - `text`

- `language`
- `rating`
- `sentiment`
- `product_category`

Difficultés supplémentaires :

- hétérogénéité linguistique
- vocabulaire non standard (Darija)
- biais de représentation

CONSIGNE MAJEURE

Le TP doit être réalisé sur les deux datasets séparément

Vous devez :

1. Construire un pipeline complet pour chaque dataset
2. Comparer les performances
3. Analyser les différences observées

PIPELINE GLOBAL

Pour chaque dataset, vous devez implémenter :

PARTIE 1 — PRÉTRAITEMENT

Travail demandé

Construire **au moins 2 pipelines** :

- Pipeline classique :
  - nettoyage
  - tokenisation
  - stopwords
  - lemmatisation
- Pipeline embedding-friendly :
  - nettoyage minimal
  - conservation du contexte

Analyse attendue

- Impact sur performances
- Différence selon dataset (mono vs multi)

PARTIE 2 — VECTORISATION

Vous devez comparer :

Méthodes classiques

- Bag of Words
- TF-IDF

Méthodes embeddings

- Word2Vec / FastText
- Sentence embeddings

Objectif :
Comparer représentation **symbolique vs sémantique**

PARTIE 3 — CLASSIFICATION

Objectif

Prédire le `sentiment`

Contraintes

Classique :

- Logistic Regression
- SVM

Embedding-based :

- modèle basé sur embeddings
- ou fine-tuning de BERT

Évaluation

- Accuracy
- Precision / Recall / F1
- Matrice de confusion

PARTIE 4 — TOPIC MODELING

Objectif

Identifier les thèmes principaux

Contraintes

Méthodes classiques :

- Latent Dirichlet Allocation

Méthodes embeddings :

- BERTopic

👉 IMPORTANT :
Vous devez comparer :

- qualité des topics
- interprétabilité
- cohérence

PARTIE 5 — SYSTÈME DE RECOMMANDATION

Objectif

Recommander des avis similaires

Contraintes

Approche 1 :

- TF-IDF + cosine similarity
- embeddings + similarité

👉 Comparaison obligatoire :

- pertinence
- robustesse (multilingue)

Approche 2 :

Concevoir un système de recommandation qui ne repose pas uniquement sur la similarité textuelle, mais qui **intègre des signaux sémantiques et qualitatifs** issus de :

- l'analyse de sentiment
- le topic modeling

Travail demandé

Vous devez proposer et implémenter une approche de recommandation enrichie permettant de :

1. Recommander des avis similaires
2. Recommander des produits pertinents

3. Prioriser les recommandations selon leur qualité et leur pertinence

Contraintes techniques

Votre système doit obligatoirement intégrer :

1- Similarité textuelle

- TF-IDF ou embeddings
- cosine similarity

2- Signal de sentiment, utiliser les résultats de classification pour :

- filtrer
  OU
- pondérer
  OU
- reclasser les recommandations

Exemple attendu :

- favoriser les avis positifs
- pénaliser les avis négatifs

3- Signal de topics, utiliser les résultats du topic modeling pour :

- mesurer la proximité thématique
- aligner les recommandations avec les préférences implicites

Approche attendue

Vous devez concevoir une fonction de scoring en justifier vos choix

---

Expérimentations demandées

Vous devez comparer au minimum :

Baseline

- recommandation basée uniquement sur similarité

Modèle enrichi

- similarité + sentiment
- similarité + topics
- similarité + sentiment + topics

Évaluation

Quantitative (si possible)

- précision des recommandations
- cohérence

Qualitative (obligatoire)

- pertinence perçue
- interprétabilité

Analyse attendue

Vous devez répondre :

- L'ajout du sentiment améliore-t-il la qualité ?
- Les topics rendent-ils la recommandation plus pertinente ?
- Quelle combinaison fonctionne le mieux ?
- Le comportement change-t-il entre dataset mono et multilingue ?

Interprétabilité (IMPORTANT)

Votre système doit être capable d'expliquer :

Exemple attendu :

> "Ce produit est recommandé car il est similaire à vos préférences et reçoit des avis positifs sur les aspects 'qualité' et 'design'"

Points de vigilance

- Attention au bruit du sentiment
- Attention à la qualité des topics
- Attention au dataset multilingue (cohérence)

BONUS (niveau excellent)

- Aspect-based sentiment analysis (sentiment par topic)
- Recommandation personnalisée (profil utilisateur simulé)
- Learning to rank (optionnel)

PARTIE 6 — ANALYSE COMPARATIVE GLOBALE

Vous devez analyser :

Différences entre datasets :

- performance
- stabilité
- robustesse

Différences entre méthodes :

- classique vs embeddings

- mono-langue vs multilingue

PARTIE 7 — ANALYSE MÉTIER

Répondre aux questions :

- Quels problèmes clients dominent ?
- Quels thèmes génèrent du négatif ?
- Le multilingue impacte-t-il la compréhension ?
- Quelle solution recommanderiez-vous en production ?

LIVRABLES

1. Notebook

- Code structuré
- Pipelines séparés par dataset

2. Rapport (4–6 pages)

Doit inclure :

- choix techniques
- comparaisons
- limites
- recommandations

3. Présentation

- 10 minutes

EXIGENCES (NIVEAU AVANCÉ)

Obligatoire :

- Cross-validation
- Hyperparameter tuning
- Analyse d'erreurs
- Justification des choix

BONUS

- Détection automatique de langue

- Gestion du code-switching
- Visualisation embeddings (t-SNE)
- API de recommandation
